数据分析课程项目

原神抽卡数据

质量分析报告

原神留存抽卡记录研究

用于记录数据来源、质量检查、清洗决定与行数对账，并说明样本的适用范围。

课程　人工智能

班级　人工智能 2 班

小组名称　哦鲸鲸

组长　刘沐泽

组员　桂曙光　丁振儒　许宏达

任课教师　梁霄

报告版本 1.0　编制日期 2026 年 10 月 21 日

目录

1 报告概述 4
1.1 编制目的 4
1.2 评估依据与方法 4
1.3 数据处理流程 4
2 评估结论摘要 5
2.1 总体结论 5
2.2 主要发现 5
2.3 优先事项 5
3 数据结构与观察口径 6
3.1 核心字段画像 6
3.2 时间字段与记录覆盖 6
4 核心明细表质量评估 7
4.1 完整性与关联 7
4.2 规范性与排序 7
4.3 唯一性与冲突隔离 7
4.4 一致性与语义准确性 7
5 数据清洗与处理结果 8
5.1 清洗规则与执行结果 8
5.2 明细设计与数据保护 8
5.3 流水线与复现 8
6 维度与参考数据质量评估 9
6.1 维表关联与卡池映射 9
6.2 历史汇总与版本甄别 9
7 分析结果与样本观察 10
7.1 卡池构成与五星占比 10
7.2 月度记录分布 11
7.3 星期小时集中程度 12
7.4 账号留存记录量 13

7.5 记录量分组与五星占比 14
7.6 记录内相邻五星间隔 15
7.7 五星原始名称记录榜 16
8 数据适用性评估 17
8.1 观察密度与适用前提 17
8.2 可以回答与不能回答的问题 17
9 问题清单与整改建议 18
9.1 问题登记 18
9.2 需来源方确认的事项 18
9.3 持续监控建议 18
10 结论 19
附录 A　数据质量检查明细 20
质量评估与解释边界 21
附录 B　字段可信度字典 22
附录 C　图表索引与复核说明 23
C.1　图表复核说明 23
C.2　来源与复现 23
附录 D　术语与缩写 24
附录 E 课程补充与大模型使用记录 26
E.1 来源与课程复核信息 26
E.2 大模型使用记录 26

1 报告概述

1.1 编制目的

本报告说明原神抽卡记录的只读清洗、质量稽核和受保护汇总过程，评价处理结果及字段语义、观察覆盖与样本选择对分析的影响。

清洗处理 15,807,577 条输入，保留 15,807,066 条，13 项工程稽核通过。主分析 03 含 16,289 个账号、15,598,804 条留存记录，用于描述卡池构成、时间集中和分布特征。

1.2 评估依据与方法

沿用评估框架的完整性、规范性、唯一性、一致性、准确性、时效性和代表性七个维度，判定依据为项目清洗规则 1.0.0 及已发布 ADS。框架案例不作为项目证据；本报告不作外部标准认证声明。

表 1-1　质量状态判定标准

结论	判定含义	使用要求
通过	既定程序断言与期望一致	在当前检查覆盖内继续发布
警告	存在已处理异常、语义疑点或观察边界	保留证据，执行规避或明确披露
不通过	关键断言失败或无法满足发布条件	停止发布并修复；本次未出现

1.3 数据处理流程

只读原始 SQLite，在项目新库完成校验、去重、隔离与排序，形成 DWD 和 DIM。DWS 重新汇总，ADS 执行小样本保护；图表、答辩与报告复用同次发布聚合。

表 1-2　数据分层与质量控制

层或环节	职责	主要控制
原始层	保留交付状态	只读；不读取 UID、个人源路径或原始 JSON/BLOB
DWD 与 DIM	校验、去重、隔离与排序	每条输入只有一个去向；保留复核标记
DWS	账号卡池、卡池、日期、物品汇总	重新计算，避免混用历史 summary 与 legacy
ADS 与交付	受保护聚合、图表及报告	5 个贡献账号门槛、互补抑制与来源清单

2 评估结论摘要

2.1 总体结论

20 项质量评估中，13 项通过、7 项警告、0 项不通过。前 13 项为自动稽核；后 7 项为报告质量评估，不计入程序检查数。总体判断为有条件使用。

输入去向、汇总、序号与关联检查均通过，说明处理过程自洽。类型编码、无时区时间、多语言名称、样本选择及观察历史仍有限制；工程对账不能证明采样完整或总体代表性。

表 2-1　关键质量与分析指标

指标	数值	统计口径
输入记录	15,807,577 条	本次全量清洗
保留记录	15,807,066 条	本次全量清洗
移除重复	511 条 0.0032%	比例分母为输入记录
冲突隔离	0 条	本次已识别冲突
自动稽核	13 项通过 0 项失败	与清洗 JSON 中的 checks 对应
主分析记录	15,598,804 条	主分析 03，固定来源口径
主分析账号	16,289 个	来源内去重，不跨来源合并

2.2 主要发现

角色活动祈愿占主分析留存抽数的 66.1%，是记录量最大的卡池。2022-01 单池月记录达到 181.3 万抽。账号留存抽数中位数为 744 抽。以上结果描述记录构成和样本分布，不换算玩家消费或总体活跃。

2.3 优先事项

后续优先向来源方确认物品类型编码、时间字段时区、历史导出的覆盖规则和样本纳入机制，并建立可追溯的多语言实体映射。在这些信息补齐前，继续采用现有规避规则和解释边界。

3 数据结构与观察口径

3.1 核心字段画像

本节依据结构字典、清洗表定义与稽核描述字段。当前发布产物未提供逐字段缺失数和唯一值总数，因此不填入未经计算的画像数字，也不展示明细示例。结构约束和记录级校验结果不能替代原始字段逐列完整性统计。

表 3-1　核心字段与使用约束

字段	类型	含义与处理	使用约束
dataset_id	INTEGER	来源分组	分析固定为 03
player_id	INTEGER	来源内账号关联键	仅本地使用，不对外发布
item_id	INTEGER	物品身份关联键	不自动合并多语言实体
gacha_type 与 pool_group	INTEGER	原卡池代码与合并池组	301/400 按角色活动池合并
gacha_time	TEXT	统一为秒级无时区字符串	不推断时区
pool_seq	INTEGER	账号池内重建连续序号	间隔基于记录序号
item_type_review	INTEGER	类型待复核标记	不得作为已核实类型使用
time_order_ambiguous	INTEGER	同秒顺序歧义标记	间隔分析排除对应账号池

3.2 时间字段与记录覆盖

主分析记录时间从 2020-12-03 23:35:23 至 2022-07-26 20:57:25。清洗统一字符串格式并验证日历合法性，本次时间规范化变更 0 条。时间未附时区信息，不能直接认定为 UTC 或北京时间；起止月也不能假定完整。

月度图按原时间自然月聚合，星期小时图按库中字符串直接解析。缺口不插值，也未按不同星期、小时的可观察天数进行曝光校正，因此时间高值只用于描述留存记录集中程度。

4 核心明细表质量评估

4.1 完整性与关联

输入去向和暂存对账均为 15,807,577 条，与期望一致；保留与隔离记录交集为 0。外键错误为 0，SQLite 快速完整性检查达到期望结果。上述证据支持本次处理没有在既定流程中丢失输入，并不证明源系统已经导出全部历史。

4.2 规范性与排序

日期、来源行、关联键与 ID 格式按清洗规则校验。抽卡 ID 始终作为文本处理，数字顺序通过长度与字典序实现，避免浮点转换损失精度。清洗后池内序号从 1 连续重建，序号断点为 0，原序号发生调整的记录共 508 条。

全量清洗中有 167,128 条记录带同秒顺序歧义标记。该标记来源于同一账号池同秒存在缺失 ID 的多条记录；保留稳定顺序不等于确认真实秒内顺序。主分析核心三池的歧义记录为 0 条，间隔聚合仍按规则排除不满足条件的账号池组合。

4.3 唯一性与冲突隔离

先按来源位置识别重复或冲突，再按账号内业务 ID 检查。同一键且内容相同只保留一条；同一键且内容矛盾则全部隔离。本次移除 511 条重复业务 ID 记录，冲突隔离 0 条。无 ID 记录不按时间与物品外观强行去重，以免误删十连中合法的同秒同物品记录。

4.4 一致性与语义准确性

四张 DWS 汇总总量均为 15,807,066 条，账号卡池与卡池星级对账异常数均为 0。另一方面，7 个来源的 10,484 条保留记录被标为类型待复核。本报告按星级、卡池和原始名称组织分析，不自动翻转类型码或将待复核编码解释为可信分类。

5 数据清洗与处理结果

5.1 清洗规则与执行结果

表 5-1　清洗执行结果

规则或指标	结果	处理决定
基础校验	最终移除原因中仅出现 duplicate_gacha_id	不额外推断未统计的字段级缺失率
重复业务 ID	511 条	保留同内容的一条，登记其余原因
冲突记录	0 条	规则为冲突候选全部隔离
时间规范化	0 条变更	不增加未经证实的时区偏移
池内序号重建	508 条变更	保留原序号作本地追溯
类型待复核	10,484 条	保留标记，不按类型码分类
保留总量	15,807,066 条	输入等于保留加移除，检查通过

5.2 明细设计与数据保护

原库保持只读，清洗写入独立新库。DWD 保留必要内部追溯键、池内序号及复核标记，不保留真实 UID 和原始抽卡 ID。DWS 仍包含本地账号粒度，不能直接作为对外交付。ADS 发布时以 5 个贡献账号为门槛；不足门槛的度量和人数一起隐藏，必要时执行互补抑制或合并相邻区间。

5.3 流水线与复现

处理依次由 python -m genshin_insight 的 clean、charts、defense 及 report 子命令显式运行，本地 import 复用各层逻辑，路径使用 pathlib，导入不连接数据库或读取业务文件。图表配置为 0.3.0+3cee80f4，清洗规则为 1.0.0。清单保留来源文件元信息、配置和代码哈希；文件元信息用于区分输入，不等同全库内容哈希。

6 维度与参考数据质量评估

6.1 维表关联与卡池映射

DIM 提供来源、账号、物品和卡池描述。明细必须能关联有效维表，来源所属账号与数据集也必须一致。外键稽核异常为 0，但关联成立只说明键在当前模型中一致，不证明所有描述字段的业务含义均已获得来源方确认。

表 6-1　维度采用口径

维度	采用口径	可信度与限制
卡池	采用源卡池维表；301/400 合并角色池	分组一致性有校验，仍保留原卡池编码
星级	采用合法的 3、4、5 星值	用于记录内星级计数与对账
物品名称	仅去首尾空白后精确汇总	翻译与别名未合并，不等同统一实体
物品类型	保留来源编码和复核标记	部分来源待确认，不用于本次分类
来源与账号	仅在来源内使用内部键	不跨来源合并为独立玩家总数

6.2 历史汇总与版本甄别

旧 summary 与 legacy 表未混入本次事实汇总，避免历史筛选条件不明或重复累计。DWS 由本次清洗后的 DWD 重建。多语言名称的合并属于后续实体映射工作，不能在本轮凭名称相似性自动完成；每项映射应保留依据和版本。

7 分析结果与样本观察

7.1 卡池构成与五星占比

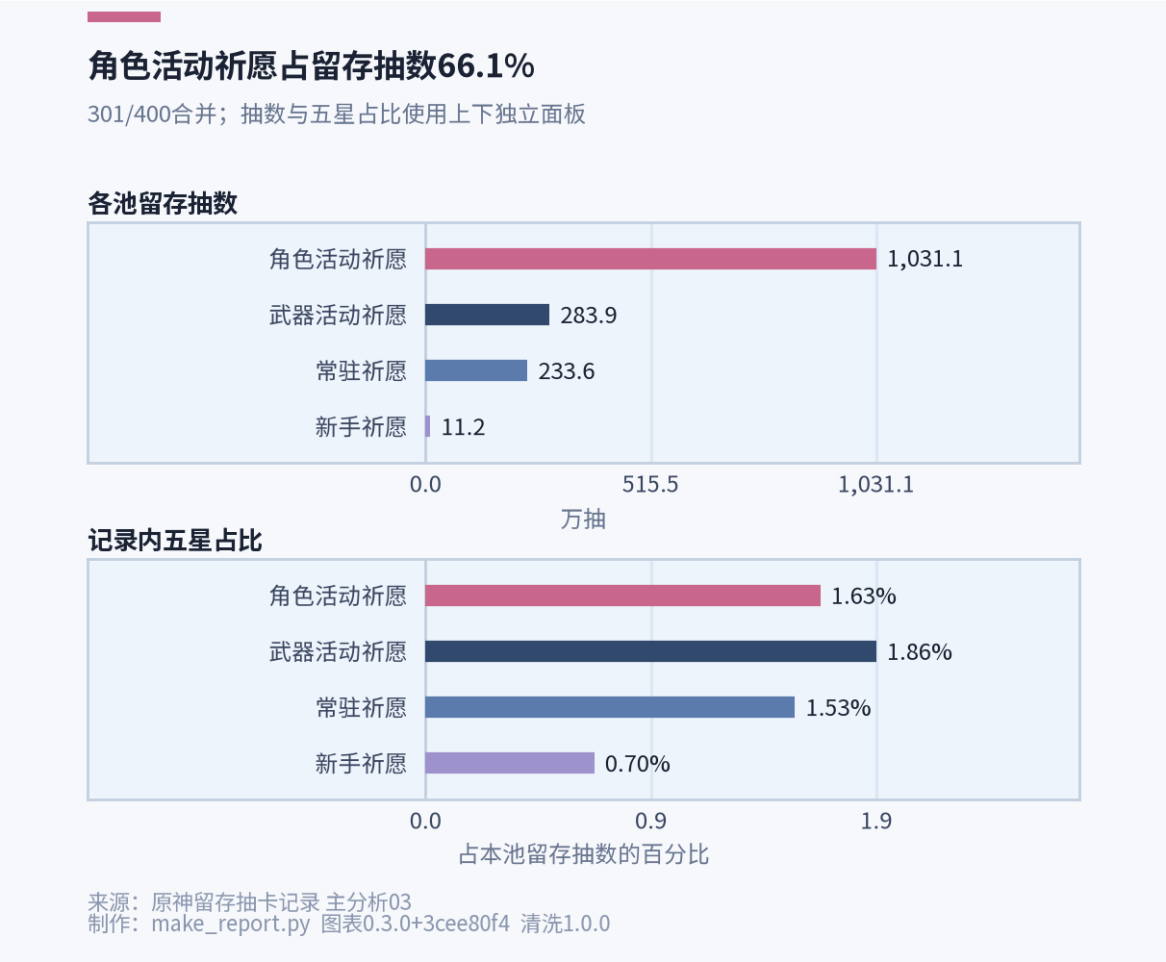


图 7-1　卡池构成与记录内五星占比

读图方式：上下独立面板分别表示各池抽数和该池五星记录占比，横轴均从 0 开始，颜色保持卡池固定映射。

关键发现：角色活动池共 10,310,849 抽，占主分析 66.1%；记录内五星数 168,055，对应占比 1.63%。

质量判断：汇总总量已对账通过；五星占比仍受记录缺失、账号选择与观察长度影响。

对分析的影响：可用于描述样本卡池构成，不能用作官方出金概率、市场份额或消费份额。

7.2 月度记录分布

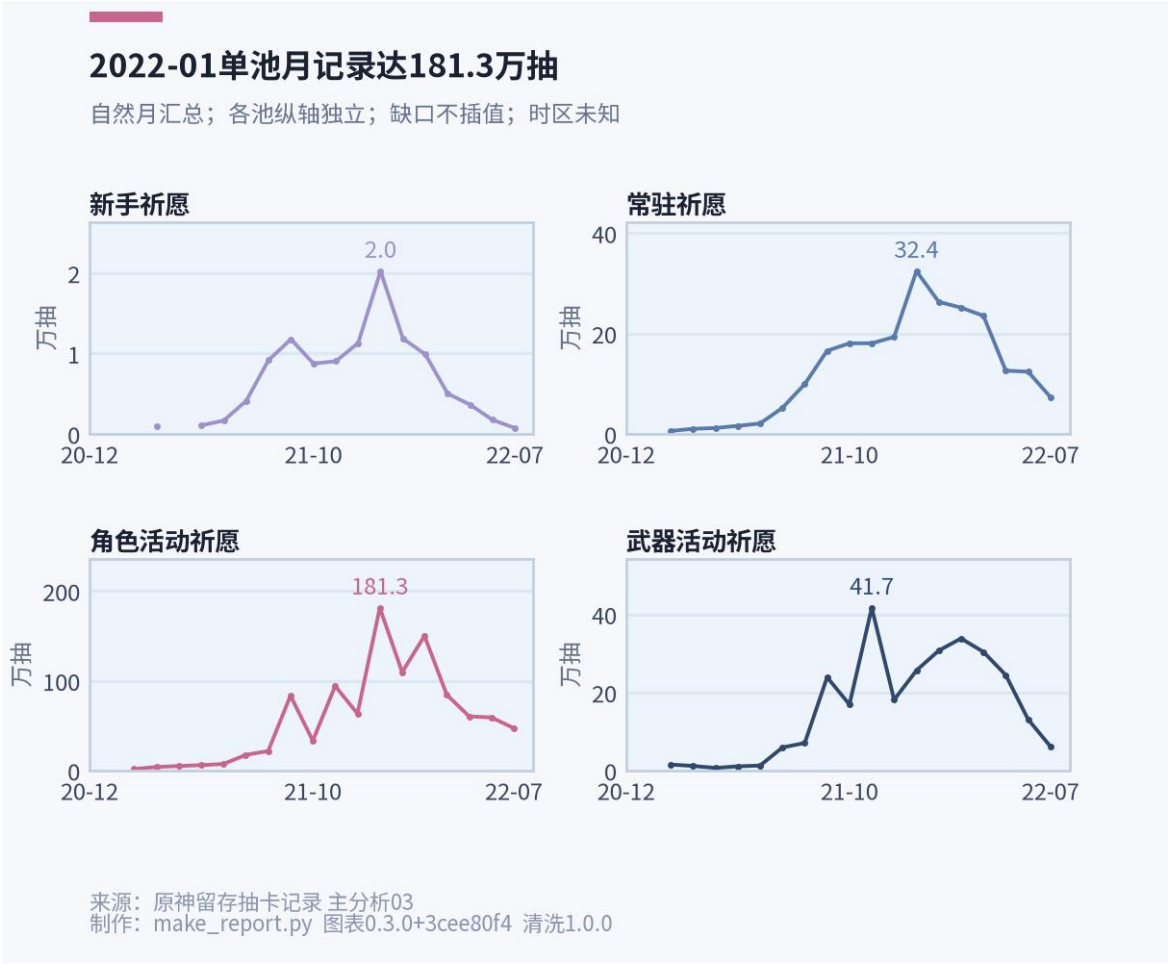


图 7-2　各卡池月度留存抽数

读图方式：四个面板表示四类卡池；横轴为自然月，纵轴为万抽，各池纵轴尺度独立，空缺保持空缺。

关键发现：2022-01 的角色活动祈愿达到单池月度峰值 181.3 万抽。

质量判断：时区、导出覆盖与曝光基数未确认，起止月可能不完整，判定为警告。

对分析的影响：仅说明留存记录高值，不能仅据时间对应关系归因于版本、活动或玩家活跃。

7.3 星期小时集中程度



图 7-3　星期与小时留存记录热力矩阵

读图方式：上下矩阵分别显示 00 至 11 时、12 至 23 时。格内数字单位为万抽，共用单粉色对数色阶，色条仍标实际数值。

关键发现：周二 18 时累计 189.4 万抽，占全部主分析抽数 12.1%。

质量判断：时间按无时区字符串直接解析，未按可观察天数校正；该统计不等于活跃人数或在线时长。

对分析的影响：可定位留存记录集中时段；进一步解释前需要时区、覆盖天数和事件口径。

7.4 账号留存记录量

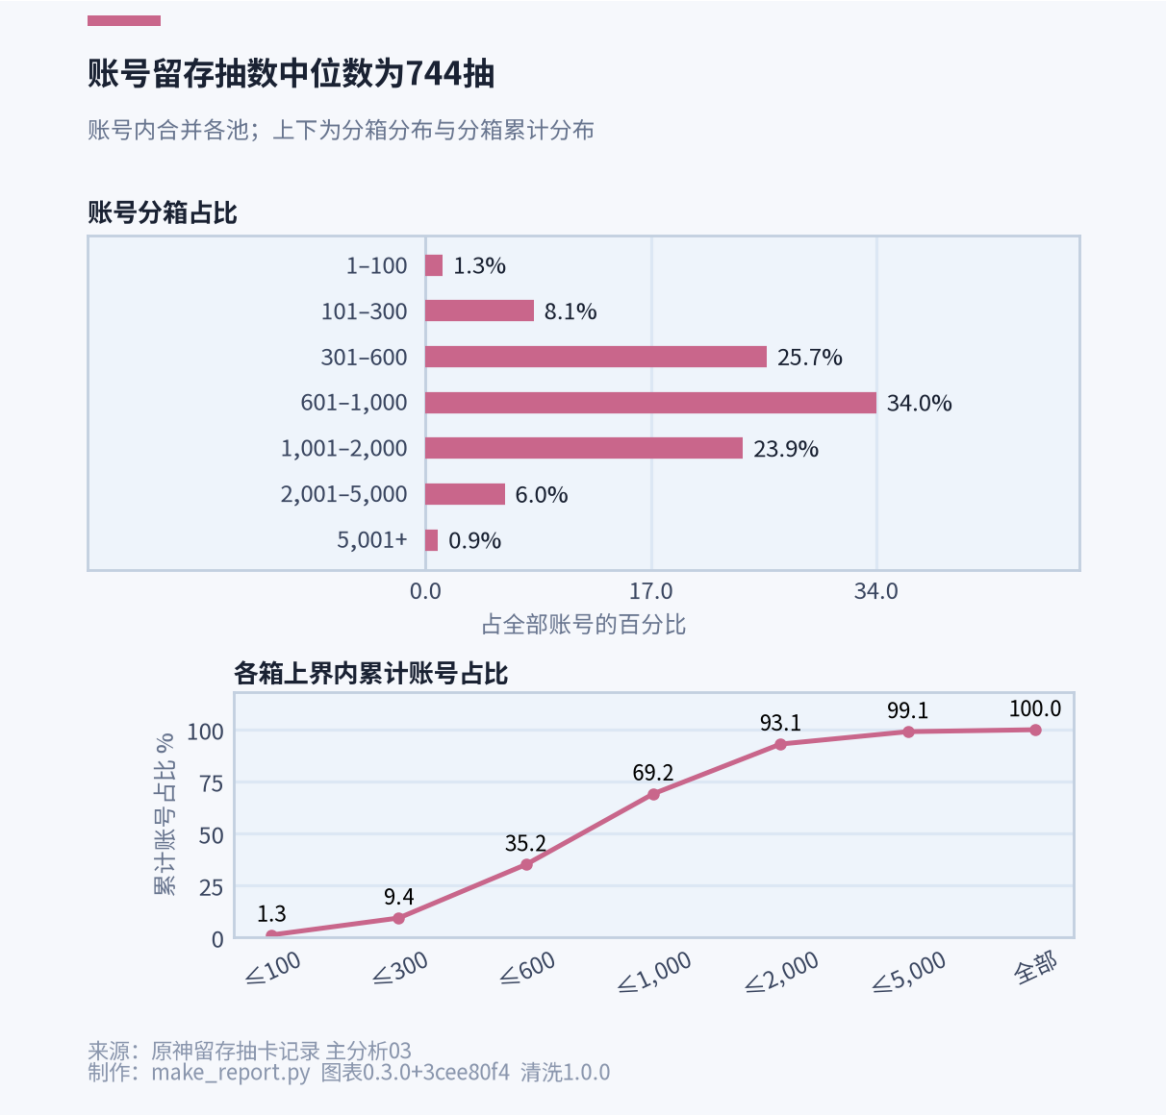


图 7-4　账号记录量与分箱累计分布

读图方式：上方横条为各抽数区间的账号占比，下方折线为各分箱上界内的累计占比；末端为开放区间。

关键发现：账号留存抽数中位数为 744 抽，抽数不超过 1,000 的账号占 69.2%。

质量判断：分箱总人数与主分析账号总数一致。累计线基于已发布安全分箱，不还原个人散点。

对分析的影响：用于比较记录量分布；记录量不等于账号完整历史、投入或付费金额。

7.5 记录量分组与五星占比

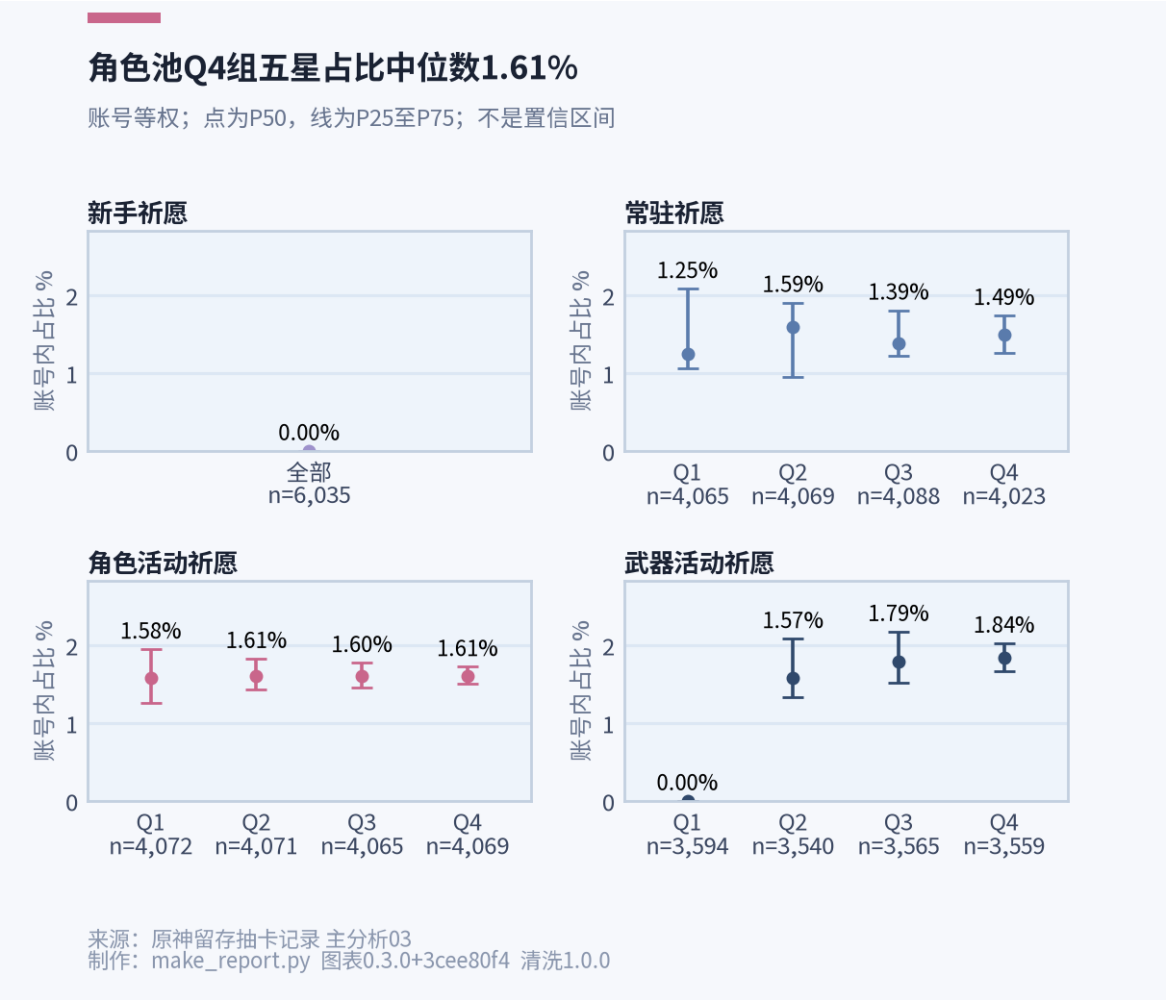


图 7-5　账号记录量分组的五星占比分布

读图方式：各池分别按账号抽数四分组，Q1 至 Q4 由低到高；点为组内账号占比中位数 P50，线为 P25 至 P75，每个账号等权。

关键发现：角色池 Q4 组中位数为 1.61%，P25 至 P75 为 1.51%至 1.72%；Q1、Q4 的 IQR 分别约 0.68 和 0.22 个百分点。

质量判断：重复分位边界会合并，新手池退化为一组。P25 至 P75 是分位区间，不能当作置信区间。

对分析的影响：图示分布差异；不能解释为抽数或付费提高概率。Q1、Q2 等不是第一季度、第二季度。

7.6 记录内相邻五星间隔

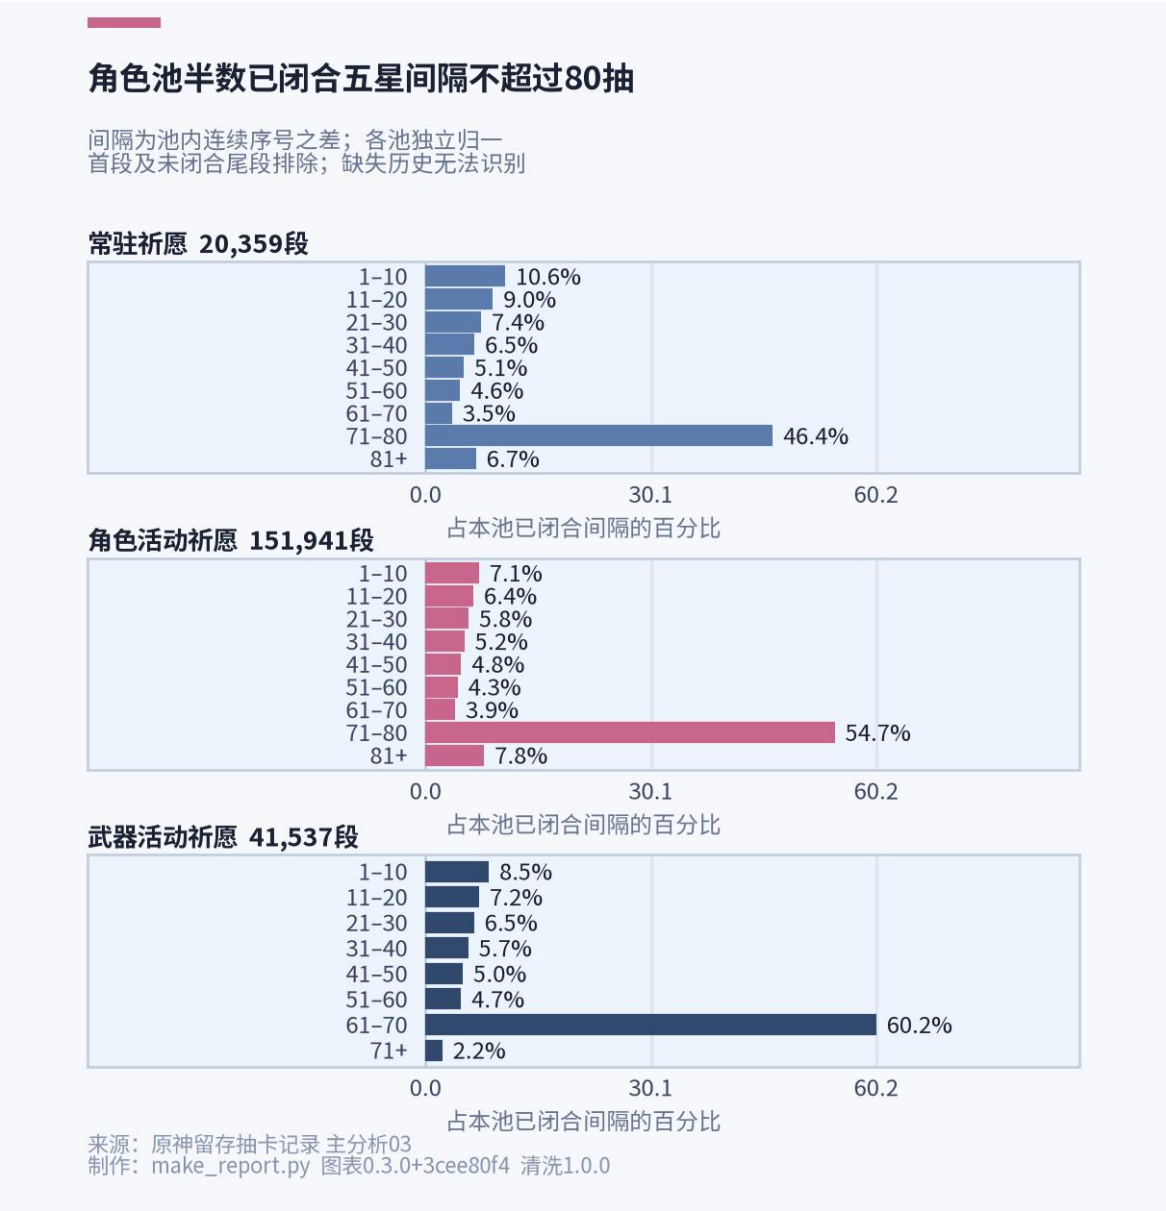


图 7-6　记录内已闭合五星间隔分布

读图方式：同一账号池相邻已记录五星的序号差；各池独立归一，稀疏尾部按各池条件合箱。

关键发现：角色池 151,941 段中，71 至 80 抽占 54.7%；中位数所在箱上界为 80 抽。

质量判断：排除首个五星前段和未闭合尾段，无法识别全部历史缺口。

对分析的影响：仅描述记录内闭合间隔，不用于真实保底、首五星等待或官方机制推断。

7.7 五星原始名称记录榜



图 7-7　五星原始名称出现次数

读图方式：横条按五星原始名称的留存次数排序，第一名强调显示，角色和武器均可进入；未合并多语言别名。

关键发现：前 12 个原始名称覆盖 55.0%的五星记录；其中雷电将军为 16,824 次。

质量判断：各名称满足贡献人数保守下界不少于 5 的发布门槛；类型待复核编码未参与分类。

对分析的影响：仅作为原始名称频数榜；解释人气需要统一实体、曝光机会和样本选择证据。

8 数据适用性评估

8.1 观察密度与适用前提

主分析可见 16,289 个账号、15,598,804 条抽卡记录，但不同账号的留存长度差异明显，中位数仅描述当前记录量。时间跨度、记录数或序号连续性都不能单独证明历史导出完整，内存或数据库中的连续序号也不能补回源历史缺口。

8.2 可以回答与不能回答的问题

表 8-1　分析能力与解释边界

分析方向	可以回答	不能回答及原因
卡池构成	样本记录中各池的抽数与星级构成	总体市场、消费份额；缺少抽样框与投入数据
时间分布	留存记录的月度和星期小时高值	活跃及事件因果；缺少时区与曝光基数
账号分布	记录量分箱、中位数与组内占比分布	完整历史、消费及概率因果；观察长度不同
五星间隔	已闭合且排序明确的记录内间隔	真实保底、首五星等待；删失与缺失未解决
名称频数	原始字符串的出现次数	实体角色人气；别名和曝光未统一

使用时须保持固定来源、卡池合并、账号等权、间隔资格和隐私保护规则。外推结论、类型分类与强机制推断应在补齐证据并更新规则后另行评估。

9 问题清单与整改建议

9.1 问题登记

责任角色为建议分工，尚非来源方承诺。警告结论与关闭状态分别管理，已处理的问题和已披露的解释边界均保留登记。

表 9-1　问题与整改清单

问题	关联	主要措施	建议责任方	状态
P-01 重复记录	DQ-14	重复规则已执行并对账；保留原始层以便追溯	项目组	已关闭
P-02 同秒顺序歧义	DQ-15	保留歧义标记；五星间隔仅使用排序明确的账号池组合	项目组	已规避
P-03 物品类型编码	DQ-16	不翻转类型码，不以其区分角色和武器；待来源方确认	来源方 项目组	待确认
P-04 时区与时间覆盖	DQ-17	按原时间自然月聚合，不作时区换算和活跃度推断	来源方 项目组	待确认
P-05 多语言名称与别名	DQ-18	名称榜按原始名称解释，不直接命名为角色人气榜	来源方 项目组	已披露
P-06 样本选择机制	DQ-19	结论限定为留存记录样本，不扩推全部玩家	来源方 项目组	待确认
P-07 五星间隔观察机制	DQ-20	排除首段和未闭合尾段；不用于官方概率或真实保底推断	项目组	已披露

9.2 需来源方确认的事项

请来源方确认类型 0 和 1 的含义、名称实体映射、时区、历史保留与截断条件、账号纳入规则及缺失 ID 原因。确认材料应保留版本和来源，不凭名称外观修改类型。

9.3 持续监控建议

每次运行须通过 13 项工程断言，跟踪重复、冲突、类型复核、排序歧义和 ADS 隐藏格。冲突、关联错误或汇总失衡时停止发布；新编码、名称和时间格式先复核。趋势阈值待积累多次运行后校准。

10 结论

本次清洗从 15,807,577 条输入中保留 15,807,066 条，移除 511 条重复，13 项自动稽核全部通过。处理去向、序号、关联和各层汇总在已定义检查范围内自洽，原始层继续作为追溯依据。

主分析 03 显示，角色活动祈愿贡献 66.1%的留存抽数，2022-01 单池月记录为 181.3 万抽，账号留存抽数中位数为 744 抽。账号分组、已闭合五星间隔和原始名称榜为样本内部比较提供了进一步证据。

报告的质量结论为有条件使用。类型编码、时区和历史覆盖、实体名称与样本选择仍限制解释力度。现阶段可交付样本内描述性分析；官方概率、真实保底、消费水平、总体活跃和角色人气等结论需要额外证据。

建议优先补齐类型字典、时间与历史导出说明和样本纳入规则，同时保留现有保护措施。获得新证据后沿相同流水线重新计算，使新增结论能够追溯到明确的规则和输入版本。

附录 A　数据质量检查明细

以下 13 项与清洗 JSON 中的 checks 顺序一一对应。编号由本报告登记，actual 与 expected 分别为实际值与期望值。

表 A-1　自动化工程稽核

编号	检查项	实际与期望	状态	证据键
DQ-01	输入记录去向对账	15,807,577 / 15,807,577	通过	input_row_accounting
DQ-02	移除原因数量对账	511 / 511	通过	rejection_reason_accounting
DQ-03	保留与隔离记录不重叠	0 / 0	通过	accepted_rejected_overlap
DQ-04	输入完整进入暂存	15,807,577 / 15,807,577	通过	source_rows_staged
DQ-05	池内序号无断点	0 / 0	通过	sequence_gaps
DQ-06	账号卡池汇总总量	15,807,066 / 15,807,066	通过	dws_player_pool_total
DQ-07	卡池汇总总量	15,807,066 / 15,807,066	通过	dws_pool_total
DQ-08	日汇总总量	15,807,066 / 15,807,066	通过	dws_daily_total
DQ-09	物品汇总总量	15,807,066 / 15,807,066	通过	dws_item_total
DQ-10	账号卡池星级对账	0 / 0	通过	dws_player_pool_rank_accounting
DQ-11	卡池星级对账	0 / 0	通过	dws_pool_rank_accounting
DQ-12	外键完整性	0 / 0	通过	foreign_key_errors
DQ-13	SQLite 快速完整性检查	1 / 1	通过	sqlite_quick_check

质量评估与解释边界

表 A-2　语义与适用性质量评估

编号与维度	检查项	证据与结论	处理决定
DQ-14 唯一性	重复记录	警告。移除 511 条重复业务 ID 记录，占输入 0.0032%	重复规则已执行并对账；保留原始层以便追溯
DQ-15 准确性	同秒顺序歧义	警告。全量清洗标记 167,128 条；主分析核心三池涉及歧义记录 0 条	保留歧义标记；五星间隔仅使用排序明确的账号池组合
DQ-16 准确性	物品类型编码	警告。7 个来源的 10,484 条记录标为待复核	不翻转类型码，不以其区分角色和武器；待来源方确认
DQ-17 时效性	时区与时间覆盖	警告。无时区时间；起止月可能不完整；缺少曝光天数与完整历史说明	按原时间自然月聚合，不作时区换算和活跃度推断
DQ-18 一致性	多语言名称与别名	警告。名称按原始字符串精确汇总，未建立统一实体映射	名称榜按原始名称解释，不直接命名为角色人气榜
DQ-19 代表性	样本选择机制	警告。缺少抽样框、纳入机制与总体对照信息	结论限定为留存记录样本，不扩推全部玩家
DQ-20 代表性	五星间隔观察机制	警告。只观察相邻已记录五星的闭合间隔，首段、尾段与历史缺失受限	排除首段和未闭合尾段；不用于官方概率或真实保底推断

附录 B　字段可信度字典

表 B-1　字段与指标可信度

字段或概念	可信度	依据与使用建议
dataset_id 与卡池分组	已验证关联	结构、分组校验与外键对账；保持来源口径
player_id	已验证内部键	来源内关联使用；不推断跨来源同一玩家
gacha_time	格式已校验 时区未知	按无时区字符串解析；不按 UTC+8 修正
gacha_id	格式与精确排序	仅清洗本地处理，未复制进 DWD，不公开标识值
pool_seq	重建规则已验证	连续性通过；不表示完整源历史
rank_type	结构与汇总已验证	合法星级范围及汇总对账；非官方概率证据
item_type	部分来源待确认	保留标记；当前不做可信角色武器分类
name	原始字符串可信	允许精确频数统计；实体映射待补充
time_order_ambiguous	规则标记	用于排除顺序不明的账号池组合
ADS 贡献人数	口径分项定义	月份、名称与间隔箱取保守下界，不能相加推算独立人数

附录 C　图表索引与复核说明

表 C-1　报告图表索引

图号	图名	发布图源	关联
图 7-1	卡池构成与记录内五星占比	A01.png	DQ-06 至 13
图 7-2	各卡池月度留存抽数	A02.png	DQ-17、19
图 7-3	星期与小时留存记录热力矩阵	A03.png	DQ-17、19
图 7-4	账号记录量与分箱累计分布	A04.png	DQ-19
图 7-5	账号记录量分组的五星占比分布	A05.png	DQ-19
图 7-6	记录内已闭合五星间隔分布	A06.png	DQ-15、20
图 7-7	五星原始名称出现次数	A07.png	DQ-18、19

C.1　图表复核说明

七张图从同次已发布 ADS 重新按 A4 版心排版，图宽 15.4 厘米、200dpi，实际刻度字号不小于 8 磅。热力矩阵按小时分为上下两块以保证数字可读，仍共用相同色阶；其余指标、分母、分组和隐私门槛保持一致。图表保存前执行项目主题禁止项检查，无双 Y 轴。

Q01 来源范围对照图仅为内部诊断，按既定汇报要求不纳入本报告。主分析账号数、抽数及日期仅在必要的统计口径处说明。

C.2　来源与复现

聚合来源为 06_复现依据/ads.json，图表配置 0.3.0+3cee80f4。自动稽核来源为对应清洗运行的 JSON 报告。报告中的表格与插图依据 06_复现依据中的受保护聚合与报告插图编排，正文数字从聚合结果计算；未重新运行原始库。各章数字与图表索引见 06_复现依据/关键数字证据.json。

附录 D　术语与缩写

表 D-1　统计与工程术语

术语	说明
统计口径	指标的对象、时间、分母、去重和分组规则；先明确这些条件，数字才可比较。
留存抽数	当前资料实际保存下来的抽卡记录条数，可能少于账号完整游戏历史。
ODS / DIM	本项目的原始数据层 / 维度描述表；DIM 用于说明物品、来源和卡池等属性。
DWD	清洗明细层；在本项目中，一行表示一条通过规则的抽卡记录。
DWS	复用汇总层；按账号池、日期、卡池或物品等粒度组织汇总。
ADS	面向图表和报告的应用结果层；发布前进行小样本保护。
粒度	一行结果代表什么统计单元，例如一个账号在一个卡池内的汇总。
TEXT / ID	TEXT 是文本类型；ID 是标识。本项目业务 ID 按数字文本处理，不转为浮点数。
pool_seq	账号在合并卡池内的已留存记录连续序号；不补造缺失抽数。
稽核 / 外键	稽核检查数量与逻辑是否对得上；外键检查表之间的关联是否有效。
互补抑制	在单个隐藏格可由总量减法反推时，再隐藏另一格；所有隐藏格使用同样标记。
贡献人数下界	能确认的最少贡献账号数；重叠汇总取已有格人数最大值，不能直接相加。
SQLite / SQL	本地文件型关系数据库 / 表达筛选、连接、聚合和窗口计算的查询语言。
Pandas / NumPy / Matplotlib	本项目分别用于表格分组、数值分位计算和图形绘制的 Python 库。
import / pathlib	导入本地可复用模块 / 用路径对象管理文件位置的 Python 模块。
量纲 / 分面	量纲指数量所属的度量类型，例如抽数与百分比；分面把不同指标放在独立坐标区。
对数色阶	颜色按数值比例而非相等差值变化；格内数字仍然是真实数量。
曝光基数	可观察天数、账号数等机会数量；缺少统一基数时，总量不能直接当作强度。
中位数	排序后位于中间位置的数值，也称第 50 百分位；重复值会使两侧人数不必恰好各半。
累计占比 / 开放尾箱	累计占比是上界以内的占比总和；开放尾箱只有下界，例如 5,001 抽及以上。

术语	说明
Q1 / Q2 / Q3 / Q4	读作第一至第四组，按账号抽数排序：Q1 约 0～25%、Q2 约 25～50%、Q3 约 50～75%、Q4 约 75～100%的排序位置；不是季度。重复边界可能导致合组。
P25 / P50 / P75	读作第 25、第 50、第 75 百分位点。本图在每个账号组内，对账号五星占比再排序计算；P50 是组内中位数。
四分位区间 / IQR	图中线段从 P25 到 P75，描述中间约 50%的账号比率；IQR 是 P75 减 P25，即四分位距。
账号等权 / 总体比率	账号等权让每个账号贡献一个比率；总体比率用五星总数除以抽数总量，等价于按抽数加权。
百分点 / 置信区间	百分点用于相减两个百分比；置信区间描述特定推断方法的不确定性。本图四分位区间没有这种含义。
qcut / 分组退化	qcut 按数值的分位边界分组；取值集中导致重复边界时合并，组数可能不足四组。
LAG / 窗口函数	LAG 读取同一账号池内前一个已记录五星的序号；窗口函数在保留记录关系的同时计算前后关联。
已闭合区间 / 右删失	已闭合区间的两个五星端点都被观察到；最后一个五星后的尾段未见下一端点，观察截止造成终点未知。
原始名称 / 名称频次	原始名称是清洗去首尾空白后的库内名称；频次计出现次数，同一账号可能重复贡献。
描述性分析 / 因果推断	前者描述给定记录中的现象；后者回答某个因素是否导致变化，需要额外设计和证据。
配置哈希	配置内容的短指纹，用于区分版本；文件大小和修改时间属于元信息，不等同于全库内容校验。

附录 E 课程补充与大模型使用记录

E.1 来源与课程复核信息

数据来源为 OneBST（一棵平衡树）发布的 OneBST/GI_gacha_dataset。DS03 取自玩家在非小酋自愿公开的记录页面，不包含玩家自行上传记录。

数据仓库：https://github.com/OneBST/GI_gacha_dataset/tree/main

DS03 说明：https://github.com/OneBST/GI_gacha_dataset/blob/main/GI_gacha_dataset_03/readme.md

来源说明发布日期为 2022-08-31，用途限定为学习和交流。网页核查日为 2026-10-21，不将其作为原始数据下载日期。

按分工计划，刘沐泽负责报告管线与统计口径，丁振儒负责评估依据与 Word 目录页码，桂曙光负责数字和图规格核对。完整签认见 04_数据与协作说明/数字交叉复核表.md。

表 E-1 课程五维要求与本报告内容对应

课程质量维度	本报告对应位置	数字与决定依据
完整性	第 4.1 节、附录 A DQ-01、04、12、13	输入 15,807,577 条，去向与暂存对账通过；不据此认定源历史完整。
规范性	第 4.2 节、附录 A DQ-05、15	序号调整 508 条，全量同秒歧义 167,128 条；保留标记并限制间隔分析。
唯一性	第 4.3 节、第 5.1 节、DQ-14	移除重复 511 条，冲突隔离 0 条；按原规则判定去向。
一致性	第 4.4 节、第 6 章、DQ-06 至 11、18	四张 DWS 总量均为 15,807,066 条；名称不自动合并。
合理性	第 3.2、4.2、4.4 节及附录 B	严格日历与格式校验；类型待复核 10,484 条、7 个来源，不猜测翻转编码。

E.2 大模型使用记录

本节登记 2026 年 10 月 21 日的材料编制辅助。此前清洗、分析、制图和答辩阶段的使用记录由小组另行归档。

表 E-2 本次大模型使用记录

项目	记录
工具与日期	Codex；2026 年 10 月 21 日

项目	记录
实际请求	参照项目任务书整理材料，先起草两份报告模板，需要的信息最后集中确认。
辅助内容	阅读任务书与规范；起草两份蓝粉主题模板；按已有聚合结果编排报告；整理提交清单与数字依据。
数字来源	既有清洗聚合稽核、受保护 ADS；未将原始明细提供给模型。
机器核验	核对输入去向、汇总总量、百分比分母、图表依据和 Word 结构；目录与 PDF 版式已检查。
未采纳项及理由	未采纳初稿中的日期占位字段，按小组要求删除。
成员人工核验	逐句核对与数字交叉复核按 04_数据与协作说明/数字交叉复核表.md 执行。

清洗规则、分析口径与结论由小组最终审定。历史使用记录按日期、提问、采纳、未采纳及原因、验证方式归档。

关联材料：04_数据与协作说明/大模型使用记录.md；数字交叉复核表.md。